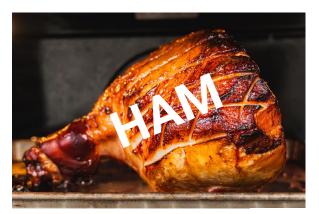
Spam Classifier

Mieux vaut déclasser le classé ou classer le déclassé ?

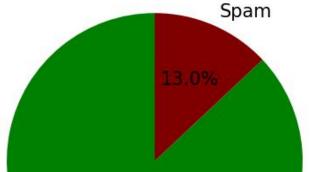
Chevallier Dylan et Proust Maximilien



5574 messages



4827 messages



747 messages

DataFrame très déséquilibré!

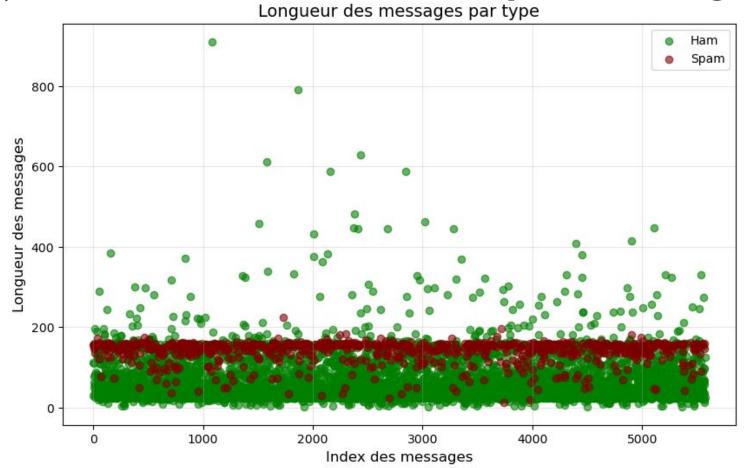
87.0%

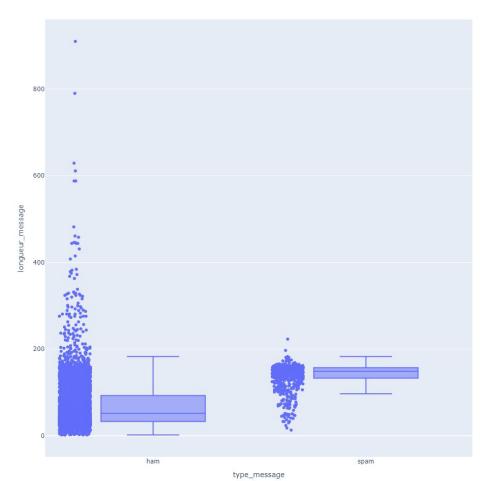
Ham

Quelles caractéristiques pour notre projet?

- Nombre de caractères par message
- Nombre de mots par type de message
- Redondance des mots types dans les spam
- La présence des chiffres dans les messages
- Le nombre de chiffre par message
- Le nombre de caractères spéciaux par type de message



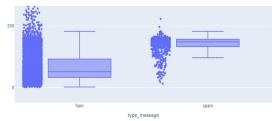


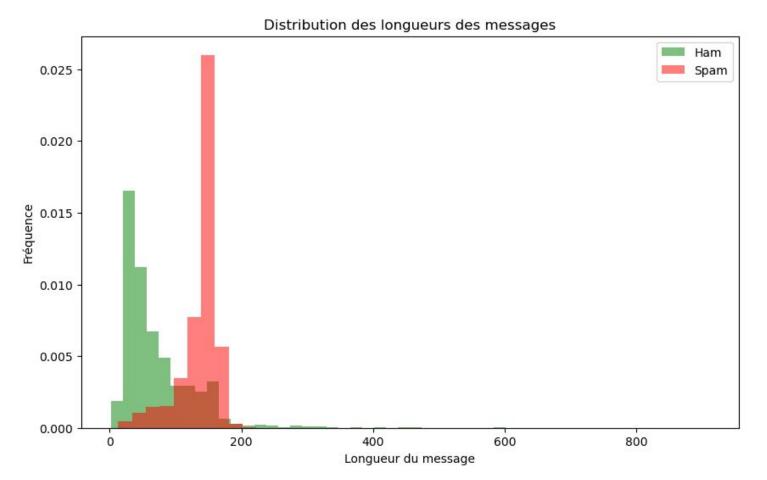


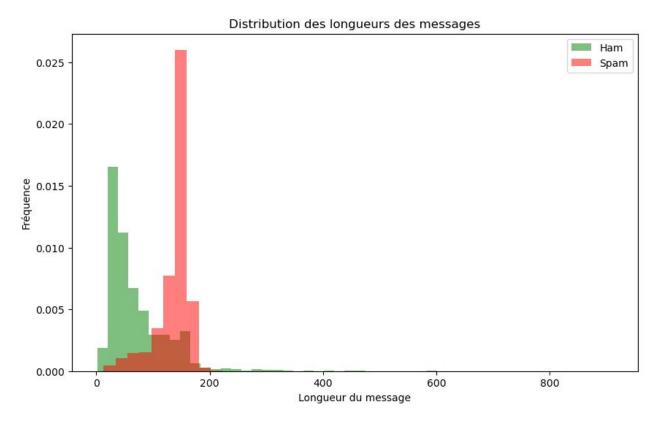


Quelques statistiques supplémentaires...

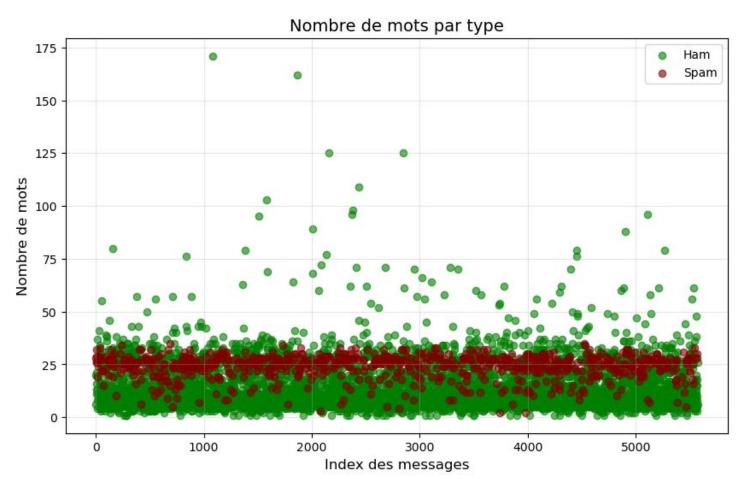
	count	mean	std	min	25%	50%	75%	max
type_message				7				1
ham	4827.0	71.47	58.33	2.0	33.0	52.0	93.0	910.0
spam	747.0	138.68	28.87	13.0	133.0	149.0	157.0	223.0
17.								

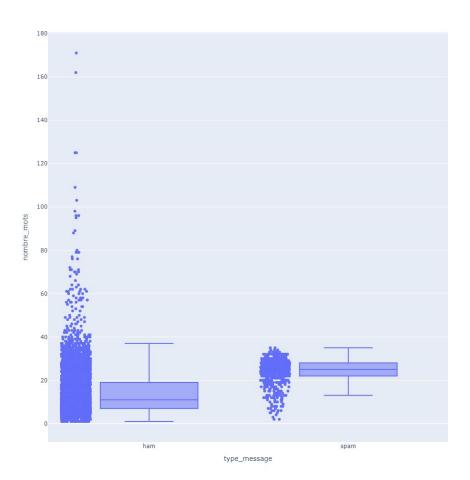


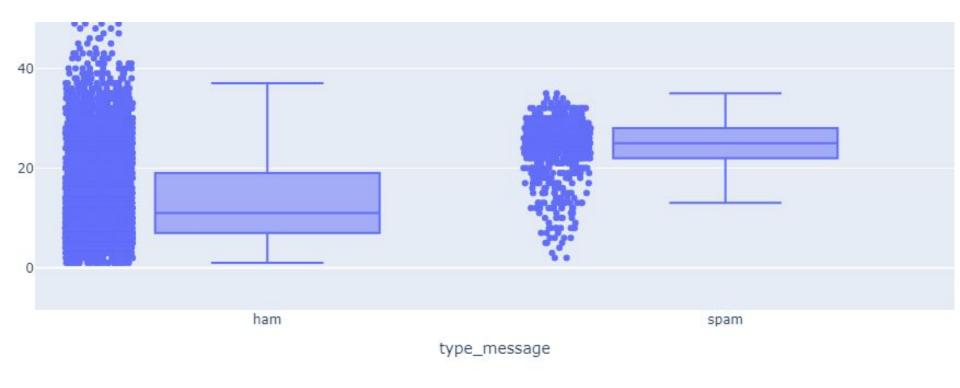




Caractéristique intéressante, on conserve!



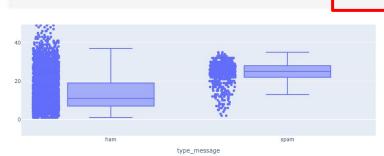




Quelques statistiques supplémentaires...

std min 25% 50% 75%

type_message								
ham	4827.0	14.30	11.50	1.0	7.0	11.0	19.0	171.0
spam	747.0	23.91	5.78	2.0	22.0	25.0	28.0	35.0



count

mean

Nombre de mots = Nombre de caractère ?

Pour le vérifier ... Test de corrélation !

Nombre de mots = Nombre de caractère?

Résultat: 0,97

Quasiment identique!

Choix : Ignorer cette caractéristique pour la suite

3) La redondance des mots présent dans les spams

	Mot	Fréquence
33	to	1538
87	you	1462
29	1	1439
83	the	1029
98	а	977
73	i	742
72	and	739
5	in	736
19	u	651
41	is	645

Pertinent ??

39	my	621
48	me	541
226	of	499
62	for	481
126	that	399
192	it	376
52	your	374
237	on	352
96	have	349
100	at	334

3)	3) La redondance des mots présent dans les spams								
				39	my	621			
	Mot	Fréquence		48	me	541			
33	to	1538		226	of	499			
87	you	1462		62	for	481			
29	I	1439	Pertinent ??	126	that	399			
83	the	1029		192	it	376			

Pas du tout!

→ Utilisation des stop words

your

have

on

at

a

and

in

u

is

3) La redondance des mots présent dans les

cname

	Mot	Frequence
38	call	187
51	Call	138
53	FREE	115
43	mobile	95
37	claim	78
66	Txt	75
165	text	73
35	prize	73
13	txt	71
265	STOP	63
104	free	62
98	reply	58

Spailis	176
	19
	157
	27
	257
	427
C'est mieux!	
	343
aintenant comptons les!	60

57 service 49 27 47 send 57 46 per 27 Nokia 46 26 45 get 43 stop 44 60 Reply 44 43 160 cash Free 151 42 new **URGENT** 41 Text

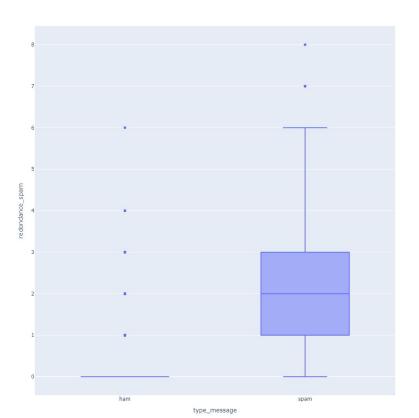
contact

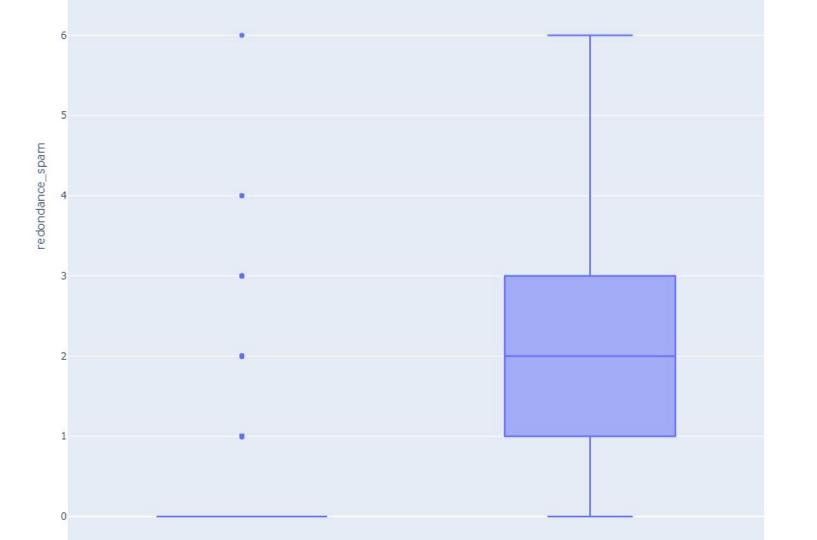
week

56

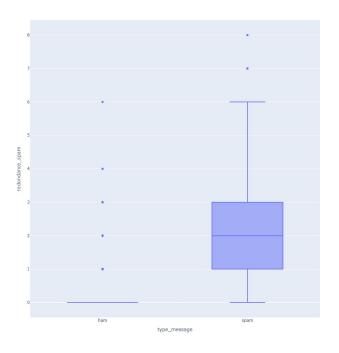
52

3) La redondance des mots présent dans les spams





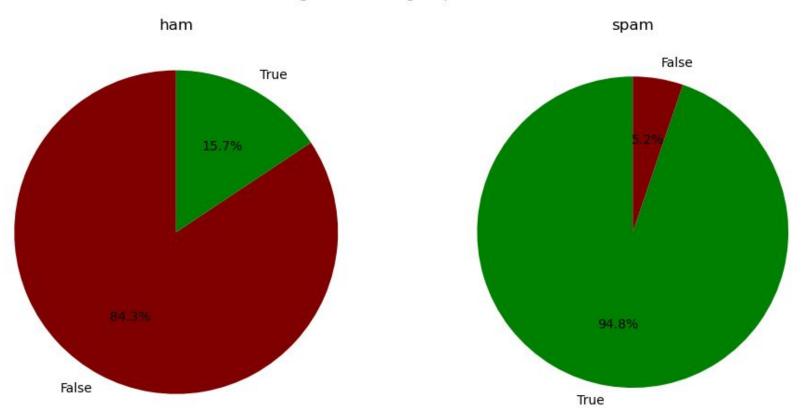
3) La redondance des mots présent dans les spams



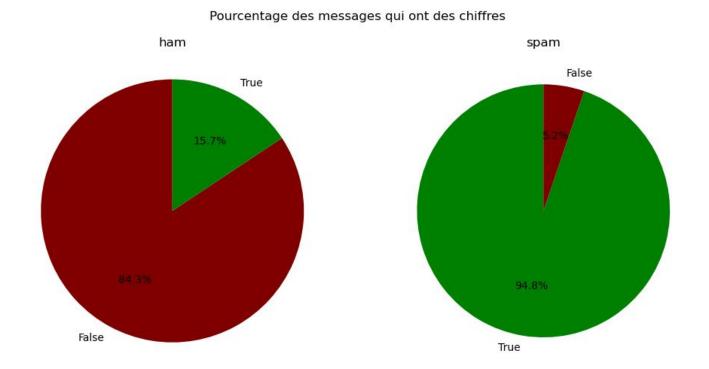
Caractéristique intéressante, on conserve!

4) La présence des chiffres dans les messages

Pourcentage des messages qui ont des chiffres

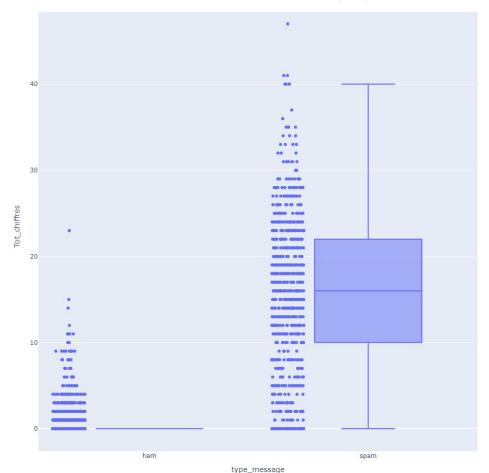


4) La présence des chiffres dans les messages

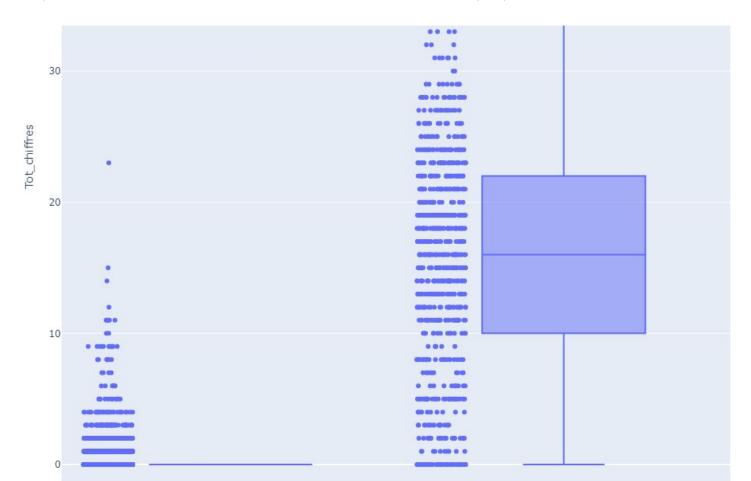


<u>Insatisfait! On en veut plus!</u>

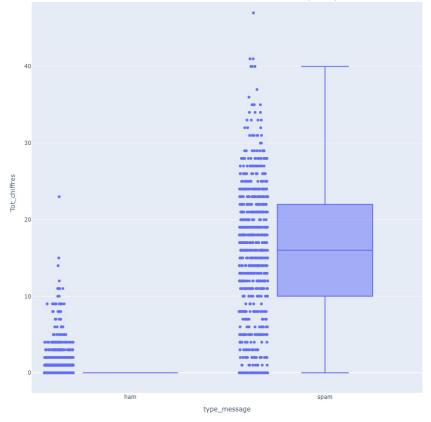
6) Le nombre de chiffre(s) par message



6) Le nombre de chiffre(s) par message



6) Le nombre de chiffre(s) par message



Caractéristique intéressante, on conserve!

Qu'est ce?

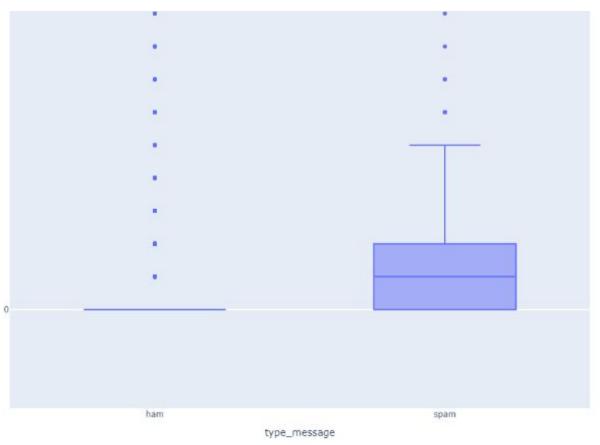
```
def caracspec(text):
    caraspe = re.findall(r'[^a-zA-Z0-9\s!"\'(),-.:;?]', text)
    return len(caraspe)
```

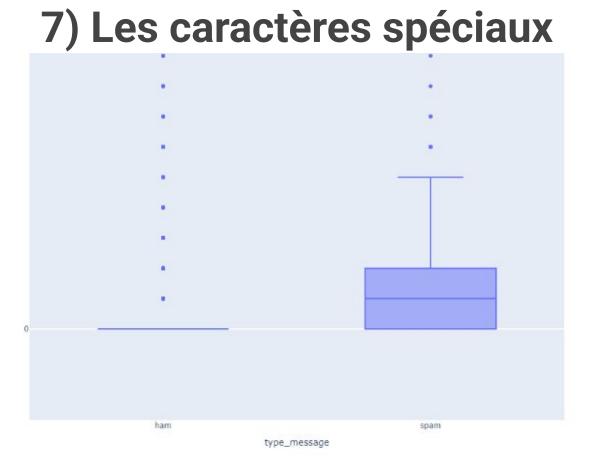
Quelques statistiques supplémentaires...

	count	mean	std	min	25%	50%	75%	max
type_message								
ham	4827.0	0.357986	1.375094	0.0	0.0	0.0	0.0	54.0
spam	747.0	1.613119	1.862999	0.0	0.0	1.0	2.0	19.0

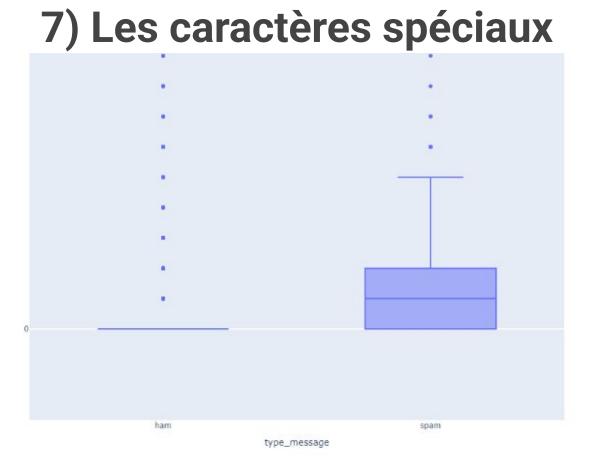
Sacré distribution!







Caractéristique intéressante, on conserve!

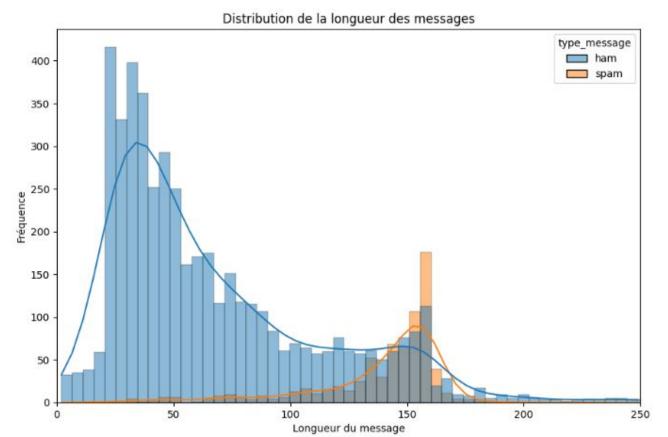


Caractéristique intéressante, on conserve!

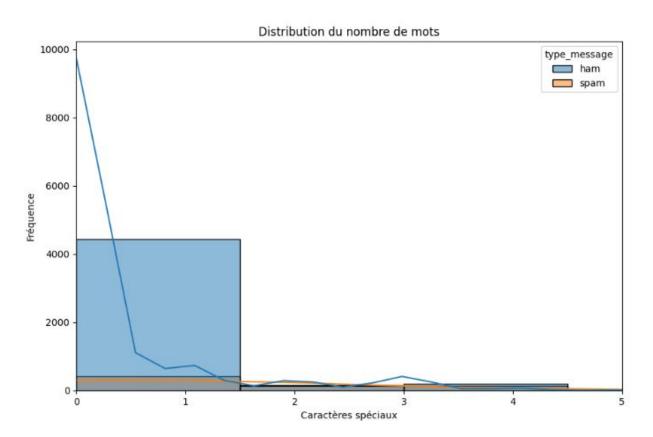
Et finalement, qu'est ce que l'on conserve ?

- La longueur des messages
- Les mots redondants des spams
 - Les chiffres totaux
 - Les caractères spéciaux

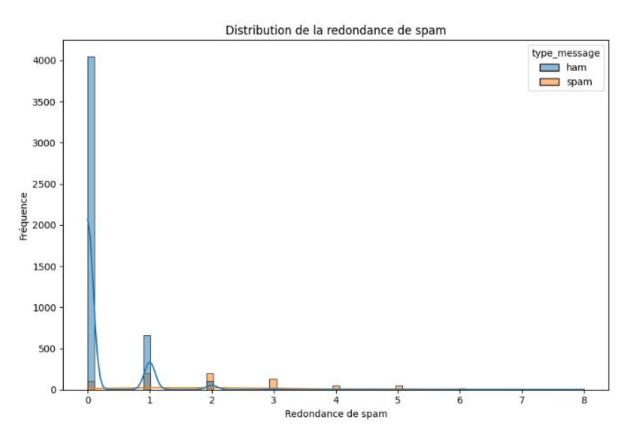
La distributivité de nos données pour choisir le modèle de normalisation



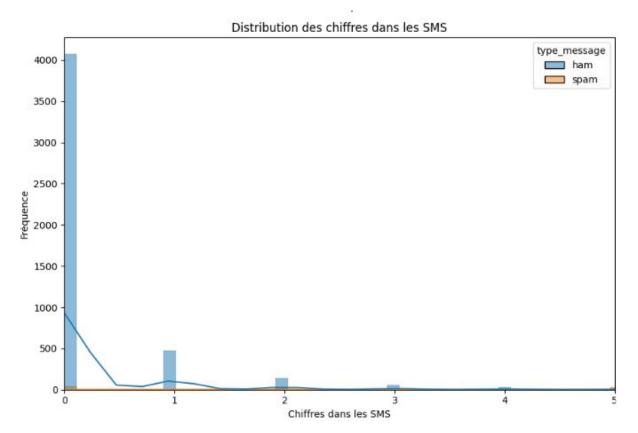
La distributivité de nos données pour choisir le modèle de normalisation



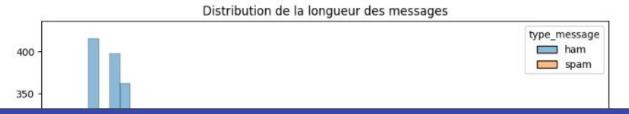
La distributivité de nos données pour choisir le modèle de normalisation



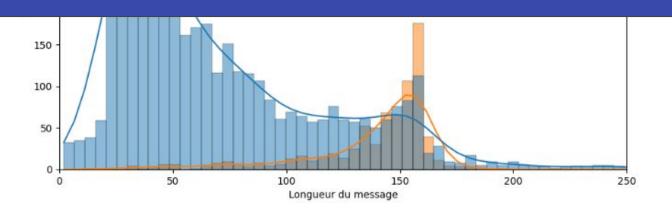
La distributivité de nos données pour choisir le modèle de normalisation



La distributivité de nos données pour choisir le modèle de normalisation



Notre choix porte sur le Standard Scaler



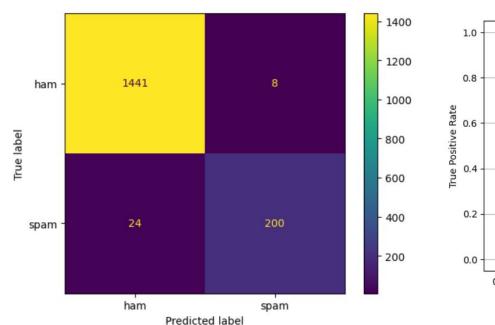
Les modèles utilisés

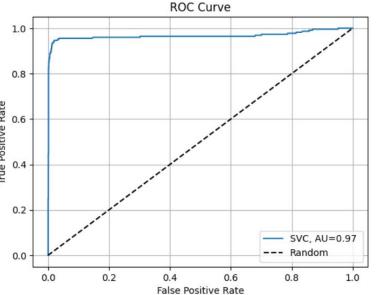
- Modèle SVC
- Modèle Logistic Regression
- Modèle Naive Bayes Gaussien
- Modèle Random Forest Classifier

Modèle 1: SVC

F1 Score: 0.923

Test de précision : 0.961

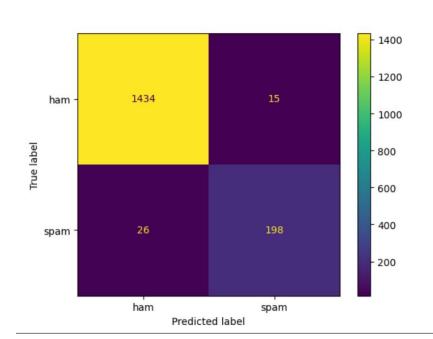


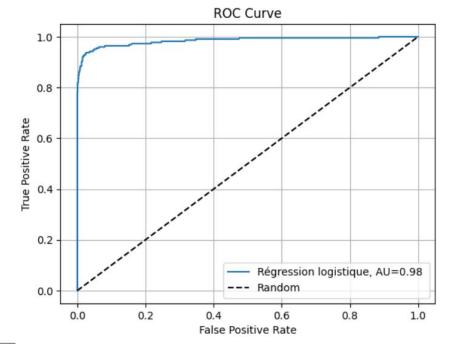


Modèle 2 : Logistic Regression

F1 Score: 0.90

Test de précision : 0.930

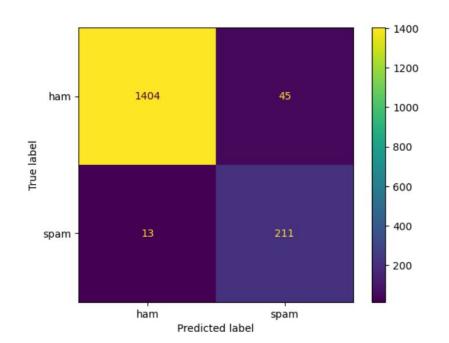


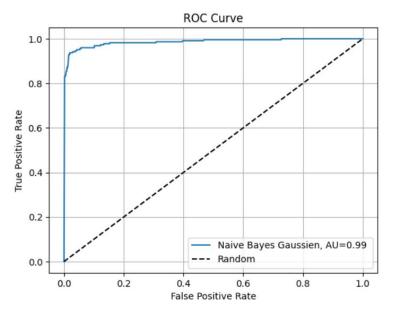


Modèle 3 : Naive Bayes Gaussien

F1 Score: 0.879

Test de précision : 0.824

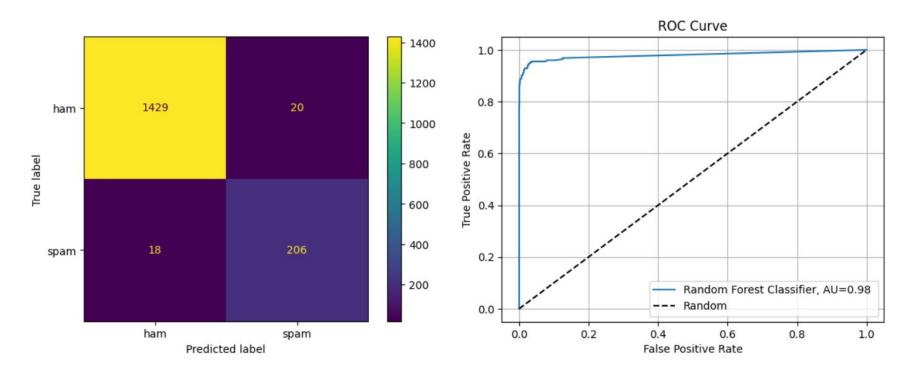




Modèle 4 : RandomForestClassifier

F1 Score: 0.916

Test de précision : 0.912



Modèle choisi:

Modèle SVC

F1 Score: 0.923

Test de précision : 0.961

AUC: 0.97

Modèle Naive Bayes

F1 Score: 0.879

Test de précision: 0.824

AUC: 0,99

Modèle Logistic Regression

F1 Score: 0.90

Test de précision : 0.930

AUC: 0.98

Modèle Random Forest Classifier

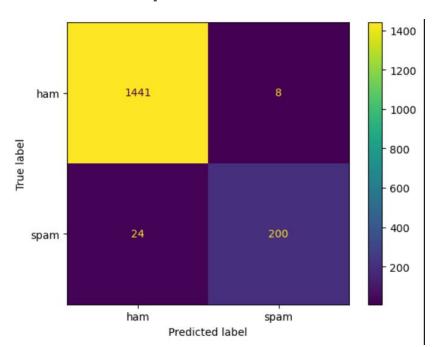
F1 Score: 0.916

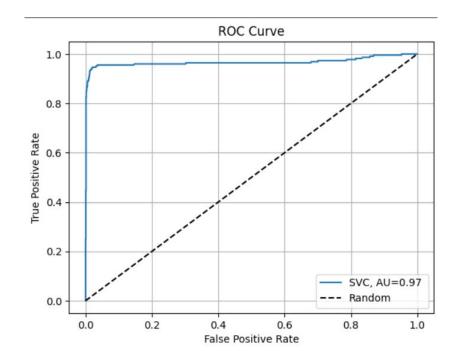
Test de précision : 0.912

Validation du Modèle choisi Modèle SVC

F1 Score: 0.926

Test de précision : 0.962





1) Application Spamlit

Interface Utilisateur Initiale

Application de Détection de Spam par apprentissage automatique Spam, pas spam ? La question ne se pose plus ! Avec nous, la réponse est à portée de main ! Saisissez un message :
réponse est à portée de main !
Saisissez un message :
Vous n'avez pas saisie de message

1) Application Spamlit

Test Application avec un message Spam



1) Application Spamlit

Test Application avec un message Ham



Problème Majeur : Il n'y a pas de détection, tout est catégoriser comme spam ou ham.

Analyse du code : Probléme d'ordres des colonnes pour la prédiction

Résolution : Reprendre l'ordre des colonnes lors de l'entraînement du Modèle utilisé

Test Spam après modification de l'ordre des colonnes

Spamlit Application de Détection de Spam par apprentissage automatique Spam, pas spam? La question ne se pose plus! Avec nous, la réponse est à portée de main! Saisissez un message: Free entry in 2 a wkly comp to win FA Cup final tkts 21st May 2005. Text FA to 87121 to receive entry question(std txt rate)T&C's apply 08452810075over18's

Prédiction d'un message de type spam du dataset correct

Test Ham après modification de l'ordre des colonnes



Prédiction d'un message de type ham du dataset correct

Message Spam qui n'est pas présent dans le dataset

Spamlit Application de Détection de Spam par apprentissage automatique Spam, pas spam? La question ne se pose plus! Avec nous, la réponse est à portée de main! Saisissez un message: Congratulations! You've been selected for a chance to win a brand-new iPhone 15 Pro! 🖋 Just text 'WIN' to 85222 to receive your prize claim instructions (standard text rates apply). Act fast—offer expires soon! T&Cs apply. Call 0800 123 4567 for details. Over 18s only. spam

Prédiction d'un message de type spam non présent dans le dataset



Merci pour votre attention, avez-vous des questions?

